



Capturing





Capturing

```
> ANY_CHAR %R% "a"
<regex> .a
> capture(ANY_CHAR) %R% "a"
<regex> (.)a
> str_extract(c("Fat", "cat"),
    pattern = ANY_CHAR %R% "a")
[1] "Fa" "ca"
> str_extract(c("Fat", "cat"),
    pattern = capture(ANY_CHAR) %R% "a")
   "Fa" "ca"
```





str_match()



str_match()

```
$5.50
```





str_match()





Non-capturing groups

```
> or("dog", "cat")
<regex> (?:dog|cat)
```

```
dog | cat
Need parentheses to distinguish
dog | cat
dog | cat
do(g | c)at
```

```
> or("dog", "cat", capture = TRUE)
<regex> (dog|cat)
> capture(or("dog", "cat"))
<regex> ((?:dog|cat))
```





Let's practice!





Backreferences



Backreferences

```
> REF1
<regex> \1
> REF2
<regex> \2
```



In a pattern

```
SPC %R%
one_or_more(WRD) %R%
SPC
```





In a pattern

```
SPC %R%
capture(one_or_more(WRD)) %R%
SPC
```



In a pattern

```
SPC %R%
capture(one_or_more(WRD)) %R%
SPC %R%
REF1
```

```
> str_view("Paris in the the spring",
    SPC %R%
    capture(one_or_more(WRD)) %R%
    SPC %R%
    REF1)
```

```
Paris in the the spring
```





In a replacement





Let's practice!





Unicode and pattern matching



Unicode

Associates each character with a code point

Character	Code Point
a	61
μ	3BC
	1F600



Unicode in R

```
> "\u03BC"
[1] "μ"

> "\U03BC"
[1] "μ"

> writeLines("\U0001F44F")
```



Unicode in R

```
> as.hexmode(utf8ToInt("a"))
[1] "61"
> as.hexmode(utf8ToInt("μ"))
[1] "3bc"
> as.hexmode(utf8ToInt("\(\text{\upsilon}\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\upsilon\uppilon\upsilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\uppilon\u
```



Matching Unicode

```
> x <- "Normal(\u03BC = 0, \u03C3 = 1)"
> x
[1] "Normal(μ = 0, σ = 1)"
> str_view(x, pattern = "\u03BC")
```

```
Normal(\mu = 0, \sigma = 1)
```

http://unicode.org/charts

http://www.fileformat.info/info/unicode/char/search.htm



Matching Unicode groups

Use \p followed by {name} Regular expression

```
> str_view_all(x, greek_and_coptic())
```

rebus

```
Normal(\mu = 0, \sigma = 1)
```

?Unicode

?unicode_property

?unicode_general_category





Let's practice!